

三维线段多平面重建 by 刘彦超

问题表达

线段表示（两端点）

$$l = \mathbf{p}_1 : (x_1, y_1, z_1) \rightarrow \mathbf{p}_2 : (x_2, y_2, z_2)$$

平面表示（点法式）

$$f = \{\mathbf{v} : (a, b, c), \mathbf{n} : (n_x, n_y, n_z)\}$$

对于给定三维线段集 $D = \{l_1, l_2, \dots, l_n\}$ ，如何重建出平面集 $\{f_1, f_2, \dots, f_k\}$ ， k 未知，使得线段到所属平面距离最小。作为聚类问题来处理。

概率建模

假设平面的数量 k 已知，同时假设各个面的概率分布 $P(f_1), P(f_2), \dots, P(f_k)$ ， $\sum_{i=1}^k P(f_i) = 1$ ，接下来对条件概率 $P(l|f_i)$ 作出如下假设：

$$P(l|f_i) = \frac{1}{\sqrt{2\pi}\sigma_i} \exp\left\{-\frac{[(\mathbf{p}_1 - \mathbf{v}_i) \cdot \mathbf{n}_i]^2 + [(\mathbf{p}_2 - \mathbf{v}_i) \cdot \mathbf{n}_i]^2}{2\sigma_i^2}\right\}$$

利用贝叶斯公式，可以得到线段样本的概率

$$P(l) = \sum_{i=1}^k P(l|f_i)P(f_i)$$

对于目前给定的三维线段集 $D = \{l_1, l_2, \dots, l_n\}$ ，假设其中每个元素都是独立的样本，采样最大似然估计来估计上面模型的各个参数。假设以上平面和先验概率分布参数集合为 θ ，接下来就是估计一个 $\hat{\theta}$ 使得 $P(D|\theta)$ 最大。

参数估计

考虑对数似然，

$$\ln[P(D|\theta)] = \sum_{i=1}^n \ln[P(l_i|\theta)] = \sum_{i=1}^n \ln\left[\sum_{j=1}^k P(l_i|f_j, \theta_j)P(f_j)\right]$$

转化为优化问题求取参数。类似于高斯混合模型，采用EM算法来进行参数估计。

- 明确隐变量

反映观测线段 l_i 来自平面 f_j 的数据是未知的，用隐变量 γ_{ij} 表示，定义如下

$$\gamma_{ij} = \begin{cases} 1, & l_i \in f_j \\ 0, & otherwise \end{cases}$$

那么可以写出完全数据的似然函数：

$$\begin{aligned}
P(l, \gamma | \theta) &= \prod_{i=1}^n P(l_i, \gamma_{i1}, \gamma_{i2}, \dots, \gamma_{ik} | \theta) \\
&= \prod_{i=1}^n \prod_{j=1}^k [P(l_i | f_j, \theta_j) P(f_j)]^{\gamma_{ij}} \\
&= \prod_{j=1}^k P(f_j)^{c_j} \prod_{i=1}^n [P(l_i | f_j, \theta_j)]^{\gamma_{ij}} \\
&= \prod_{j=1}^k P(f_j)^{c_j} \prod_{i=1}^n \left[\frac{1}{\sqrt{2\pi}\sigma_j} \exp \left(-\frac{((\mathbf{p}_{i1} - \mathbf{v}_j) \cdot \mathbf{n}_j)^2 + ((\mathbf{p}_{i2} - \mathbf{v}_j) \cdot \mathbf{n}_j)^2}{2\sigma_j^2} \right) \right]^{\gamma_{ij}}
\end{aligned}$$

这里 $c_j = \sum_{i=1}^n \gamma_{ij}$ ，完全数据的对数似然函数为

$$\ln P(l, \gamma | \theta) = \sum_{j=1}^k \left\{ c_j \ln P(f_j) + \sum_{i=1}^n \gamma_{ij} \left[\ln \frac{1}{\sqrt{2\pi}\sigma_j} - \frac{1}{2\sigma_j^2} ((\mathbf{p}_{i1} - \mathbf{v}_j) \cdot \mathbf{n}_j)^2 + ((\mathbf{p}_{i2} - \mathbf{v}_j) \cdot \mathbf{n}_j)^2 \right] \right\}$$

- 确定Q函数

EM算法的E的步骤，确定Q函数

$$\begin{aligned}
Q(\theta, \theta^{(i)}) &= \mathcal{E}[\ln P(l, \gamma | \theta) | l, \theta^{(i)}] \\
&= \mathcal{E} \left\{ \sum_{j=1}^k \left\{ c_j \ln P(f_j) + \sum_{i=1}^n \gamma_{ij} \left[\ln \frac{1}{\sqrt{2\pi}\sigma_j} - \frac{((\mathbf{p}_{i1} - \mathbf{v}_j) \cdot \mathbf{n}_j)^2 + ((\mathbf{p}_{i2} - \mathbf{v}_j) \cdot \mathbf{n}_j)^2}{2\sigma_j^2} \right] \right\} \right\} \\
&= \sum_{j=1}^k \left\{ \sum_{i=1}^n \mathcal{E}(\gamma_{ij}) \ln P(f_j) + \sum_{i=1}^n \mathcal{E}(\gamma_{ij}) \left[\ln \frac{1}{\sqrt{2\pi}\sigma_j} - \frac{((\mathbf{p}_{i1} - \mathbf{v}_j) \cdot \mathbf{n}_j)^2 + ((\mathbf{p}_{i2} - \mathbf{v}_j) \cdot \mathbf{n}_j)^2}{2\sigma_j^2} \right] \right\}
\end{aligned}$$

计算期望 $\mathcal{E}(\gamma_{ij} | l_i, \theta)$ ，记为 $\hat{\gamma}_{ij}$ ：

$$\begin{aligned}
\hat{\gamma}_{ij} &= \mathcal{E}(\gamma_{ij} | l_i, \theta) = P(\gamma_{ij} = 1 | l_i, \theta_j) \\
&= \frac{P(\gamma_{ij} = 1, l_i | \theta_j)}{\sum_{j=1}^k P(\gamma_{ij} = 1, l_i | \theta_j)} \\
&= \frac{P(l_i | \gamma_{ij} = 1, \theta_j) P(\gamma_{ij} = 1 | \theta)}{\sum_{j=1}^k P(l_i | \gamma_{ij} = 1, \theta_j) P(\gamma_{ij} = 1 | \theta)} \\
&= \frac{P(f_j) P(l_i | f_j, \theta)}{\sum_{j=1}^k P(f_j) P(l_i | f_j, \theta)}
\end{aligned}$$

将 $\hat{\gamma}_{ij}$, $c_j = \sum_{i=1}^n \hat{\gamma}_{ij}$ 代入Q函数得到

$$Q(\theta, \theta^{(i)}) = \sum_{j=1}^k c_j \ln P(f_j) + \sum_{i=1}^n \hat{\gamma}_{ij} \left[\ln \frac{1}{\sqrt{2\pi}\sigma_j} - \frac{((\mathbf{p}_{i1} - \mathbf{v}_j) \cdot \mathbf{n}_j)^2 + ((\mathbf{p}_{i2} - \mathbf{v}_j) \cdot \mathbf{n}_j)^2}{2\sigma_j^2} \right]$$

- 求极大

因为 $\sum_{i=1}^k P(f_i) = 1$ 约束最优化问题可以写成

$$\begin{aligned}
&\max_{\theta} Q(\theta, \theta^{(i)}) \\
&s. t. \sum_{j=1}^k P(f_j) = 1
\end{aligned}$$

写成拉格朗日函数：

$$\mathcal{L} = Q(\theta, \theta^{(i)}) + \lambda \left[1 - \sum_{j=1}^k P(f_j) \right]$$

对 $P(f_j)$ 求偏导并令其为0

$$\frac{\partial \mathcal{L}}{\partial P(f_j)} = \frac{c_j}{P(f_j)} - \lambda = 0 \Rightarrow c_j = \lambda P(f_j) \Rightarrow \sum_{j=1}^n c_j = \sum_{j=1}^n \lambda P(f_j) \Rightarrow \lambda = n \Rightarrow P(f_j) = \frac{c_j}{n}$$

对 σ_j 求偏导并令其为0

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial \sigma_j} &= \sum_{i=1}^n \hat{\gamma}_{ij} \frac{((\mathbf{p}_{i1} - \mathbf{v}_j) \cdot \mathbf{n}_j)^2 + ((\mathbf{p}_{i2} - \mathbf{v}_j) \cdot \mathbf{n}_j)^2 - \sigma_j^2}{\sigma_j^3} = 0 \\ &\Downarrow \\ \sigma_j^2 &= \frac{\sum_{i=1}^n \hat{\gamma}_{ij} [((\mathbf{p}_{i1} - \mathbf{v}_j) \cdot \mathbf{n}_j)^2 + ((\mathbf{p}_{i2} - \mathbf{v}_j) \cdot \mathbf{n}_j)^2]}{\sum_{i=1}^n \hat{\gamma}_{ij}} \end{aligned}$$

对 \mathbf{n}_j 求偏导并令其为0

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial \mathbf{n}_j} &= - \sum_{i=1}^n \frac{\hat{\gamma}_{ij}}{\sigma_j^2} [(\mathbf{p}_{i1} - \mathbf{v}_j)^T \mathbf{n}_j (\mathbf{p}_{i1} - \mathbf{v}_j) + (\mathbf{p}_{i2} - \mathbf{v}_j)^T \mathbf{n}_j (\mathbf{p}_{i2} - \mathbf{v}_j)] = 0 \\ &\Downarrow \\ -\frac{1}{\sigma_j^2} \left\{ \sum_{i=1}^n \hat{\gamma}_{ij} [(\mathbf{p}_{i1} - \mathbf{v}_j)(\mathbf{p}_{i1} - \mathbf{v}_j)^T + (\mathbf{p}_{i2} - \mathbf{v}_j)(\mathbf{p}_{i2} - \mathbf{v}_j)^T] \right\} \mathbf{n}_j &= 0 \end{aligned}$$

令

$$A = \left\{ \sum_{i=1}^n \hat{\gamma}_{ij} [(\mathbf{p}_{i1} - \mathbf{v}_j)(\mathbf{p}_{i1} - \mathbf{v}_j)^T + (\mathbf{p}_{i2} - \mathbf{v}_j)(\mathbf{p}_{i2} - \mathbf{v}_j)^T] \right\}$$

解线性方程 $A\mathbf{n}_j = 0$ 得到 \mathbf{n}_j , 但是该方程不一定有非零解。考虑到这一点, 将该问题再转化为优化的问题

$$\min_{\mathbf{n}_j} \|A\mathbf{n}_j\|$$

因为尺度大小的影响, 对 \mathbf{n}_j 再加入一个约束 $\|\mathbf{n}_j\| = 1$, 可以得到

$$\begin{aligned} \min_{\mathbf{n}_j} \mathbf{n}_j^T A^T A \mathbf{n}_j \\ s. t. \mathbf{n}_j^T \mathbf{n}_j = 1 \end{aligned}$$

等价于对 $A^T A$ 进行特征值分解, 因为 $A^T A$ 半正定, 而且 A 是半正定对称矩阵, 所以 A 最小特征值对应的特征向量即为 \mathbf{n}_j ;

对 \mathbf{v}_j 求偏导并令其为0

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial \mathbf{v}_j} &= \sum_{i=1}^n \frac{\hat{\gamma}_{ij}}{\sigma_j^2} [\mathbf{n}_j^T (\mathbf{p}_{i1} - \mathbf{v}_j) \mathbf{n}_j + \mathbf{n}_j^T (\mathbf{p}_{i2} - \mathbf{v}_j) \mathbf{n}_j] = 0 \\ &\Downarrow \\ \frac{1}{\sigma_j^2} \sum_{i=1}^n \hat{\gamma}_{ij} [\mathbf{n}_j \mathbf{n}_j^T (\mathbf{p}_{i1} + \mathbf{p}_{i2} - 2\mathbf{v}_j)] &= 0 \\ &\Downarrow \\ \frac{1}{\sigma_j^2} \mathbf{n}_j \mathbf{n}_j^T \left[\sum_{i=1}^n \hat{\gamma}_{ij} (\mathbf{p}_{i1} + \mathbf{p}_{i2}) \right] &= \frac{2}{\sigma_j^2} \mathbf{n}_j \mathbf{n}_j^T \left(\sum_{i=1}^n \hat{\gamma}_{ij} \right) \mathbf{v}_j \\ &\Downarrow \\ \mathbf{v}_j &= \frac{\sum_{i=1}^n \hat{\gamma}_{ij} (\mathbf{p}_{i1} + \mathbf{p}_{i2})}{2 \sum_{i=1}^n \hat{\gamma}_{ij}} \end{aligned}$$

算法描述

输入：三维线段集 $D = \{l_1, l_2, \dots, l_n\}$, 概率模型

输出：概率模型参数

1. 取参数的初值开始迭代
2. E步：依据当前模型参数，计算平面对线段的响应度

$$\hat{\gamma}_{ij} = \frac{P(f_j)P(l_i|f_j, \theta)}{\sum_{j=1}^k P(f_j)P(l_i|f_j, \theta)}, \quad i = 1, 2, \dots, n, \quad j = 1, 2, \dots, k$$

3. M步：计算新一轮迭代的模型参数,

$$\begin{aligned} \hat{P}(f_j) &= \frac{\sum_{i=1}^n \hat{\gamma}_{ij}}{n}, \quad j = 1, 2, \dots, k \\ \hat{\sigma}_j^2 &= \frac{\sum_{i=1}^n \hat{\gamma}_{ij} [((\mathbf{p}_{i1} - \mathbf{v}_j) \cdot \mathbf{n}_j)^2 + ((\mathbf{p}_{i2} - \mathbf{v}_j) \cdot \mathbf{n}_j)^2]}{\sum_{i=1}^n \hat{\gamma}_{ij}}, \quad j = 1, 2, \dots, k \\ A &= \sum_{i=1}^n \hat{\gamma}_{ij} [(\mathbf{p}_{i1} - \mathbf{v}_j)(\mathbf{p}_{i1} - \mathbf{v}_j)^T + (\mathbf{p}_{i2} - \mathbf{v}_j)(\mathbf{p}_{i2} - \mathbf{v}_j)^T], A\hat{\mathbf{n}}_j = \lambda_{\min} \hat{\mathbf{n}}_j, \quad j = 1, 2, \dots, k \\ \hat{\mathbf{v}}_j &= \frac{\sum_{i=1}^n \hat{\gamma}_{ij} (\mathbf{p}_{i1} + \mathbf{p}_{i2})}{2 \sum_{i=1}^n \hat{\gamma}_{ij}} \end{aligned}$$

4. 重复2、3步直到收敛。

根据最终的 $\mathbf{v}_j, \mathbf{n}_j (j = 1, 2, \dots, k)$ 即可确定最后的平面集合。


TODO

类似于GMM到K-Means的简化，算法简化假设先验概率相等，后验概率0-1近似。和K-Means一样，模型对初值敏感，对outlier敏感。目前初值是选取模型包围盒对角线上的n点，每个点三个互相正交的平面。方差初始值设为两个面之间的距离


Results

cluster/3, iteration times

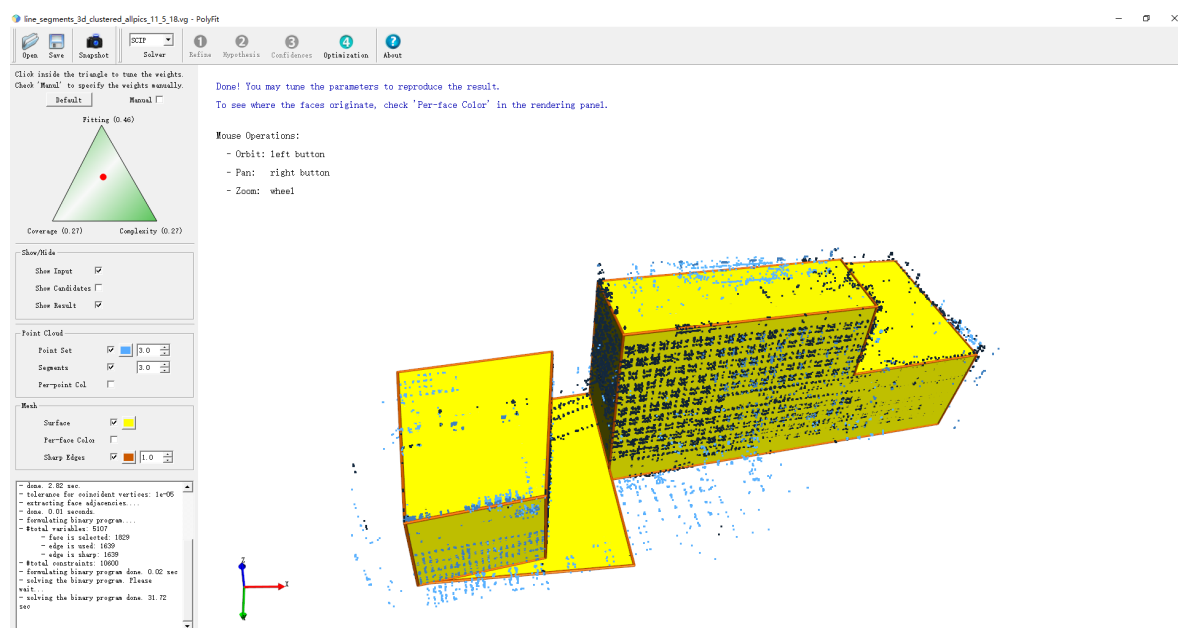

(11,22) 先进院部分面采样

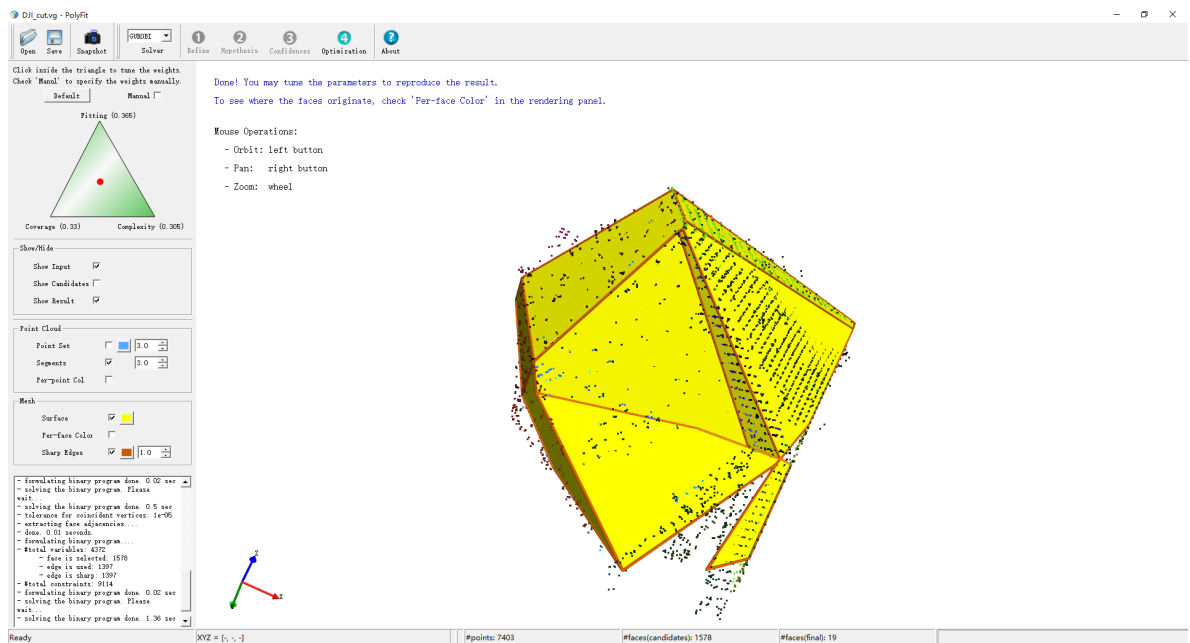


(19,25)大疆旗舰店



(15,30)先进院





(41,50)大疆modified

